



**PROPOSAL
PROYEK AKHIR**

**CROSS-DATASET EVALUATION OF IOT/IIOT
INTRUSION DETECTION MODEL
GENERALIZATION ON CIC IIOT 2025**

Wahyu Ikbal Maulaana
NRP. 3323600056

DOSEN PEMBIMBING
Dr. Ferry Astika Saputra, S.T., M.Sc.
NIP. 197708232001121002

Dr. Tita Karlita, S.Kom., M.Kom.
NIP. 197910142002122002

**PROGRAM STUDI SARJANA TERAPAN
SAINS DATA TERAPAN
JURUSAN TEKNIK INFORMATIKA DAN
KOMPUTER
POLITEKNIK ELEKTRONIKA NEGERI SURABAYA
2026**

BAB. I

PENDAHULUAN

1.1 LATAR BELAKANG

Perkembangan Internet of Things (IoT) dan Industrial Internet of Things (IIoT) telah mendorong adopsi perangkat terhubung secara masif di berbagai sektor, mulai dari konsumen rumahan hingga infrastruktur industri kritis. Ekspansi ini membuka permukaan serangan yang luas bagi penyerang siber, sementara karakteristik domain yang berbeda — IoT yang bersifat consumer-focused dan IIoT yang bersifat industri-focused — menambahkan kompleksitas dalam perancangan sistem keamanan jaringan. Untuk menjawab tantangan ini, komunitas riset telah menghasilkan dataset benchmark seperti CICIoT2023 dan DataSense (CIC IIoT 2025) guna memfasilitasi pengembangan dan evaluasi IDS berbasis machine learning.

CICIoT2023 dirancang sebagai dataset serangan IoT berskala besar yang dibangun di atas topologi nyata dengan 105 perangkat dan 33 skenario serangan dalam tujuh kategori. Dataset ini telah menjadi benchmark utama bagi berbagai penelitian IDS berbasis machine learning yang menghasilkan berbagai model IDS terpublikasi dengan performa kompetitif [8], [10], [11]. Di sisi lain, DataSense sebagai CIC IIoT 2025 menghadirkan testbed IIoT yang realistis di laboratorium CIC-UNB, meliputi sensor industri berbasis Arduino MKR WiFi 1010 (cuaca, air, tanah, uap, gas, suara, getar, ultrasonik, cahaya, akselerometer, gerak, RFID, dan api), kamera pengawas, smart plug, serta MQTT broker berbasis Raspberry Pi, dan mengintegrasikan data sensor serta jaringan yang disinkronkan dengan pendekatan multi-objective feature selection [1]. Kombinasi kedua dataset ini menjadikan studi cross-dataset menarik untuk dieksplorasi lebih lanjut.

Berdasarkan celah tersebut, penelitian ini bertujuan melakukan evaluasi cross-dataset terhadap generalisasi model deteksi intrusi IoT/IIoT, dengan menggunakan model-model yang telah dipublikasikan dari CICIoT2023 dan mengujinya pada dataset DataSense (CIC IIoT 2025). Penelitian ini akan menganalisis karakteristik kedua dataset secara mendalam, mengevaluasi performa berbagai keluarga algoritma machine learning — meliputi tree-based, ensemble, dan deep learning — lintas domain, mengidentifikasi fitur yang paling robust, serta menghasilkan rekomendasi praktis bagi peneliti yang ingin menerapkan machine learning pada dataset CIC IIoT 2025 sebagai rujukan foundational.

1.2 PERMASALAHAN

Penelitian ini berangkat dari permasalahan bahwa model intrusion detection berbasis machine learning yang dilatih pada dataset IoT sering kali menunjukkan performa tinggi secara in-dataset, namun belum terbukti mampu mempertahankan performa yang sama ketika diterapkan pada lingkungan IIoT yang memiliki karakteristik berbeda. Perbedaan jenis perangkat, protokol, pola trafik, dan kondisi operasional antara CICIoT2023 dan DataSense (CIC IIoT 2025) berpotensi menimbulkan domain shift yang signifikan sehingga menurunkan kemampuan generalisasi model [1], [2].

1.3 TUJUAN

Penelitian proyek akhir ini mengajukan suatu kerangka evaluasi baru untuk mengatasi permasalahan generalisasi model intrusion detection berbasis machine learning lintas domain IoT dan IIoT, dengan menggunakan pendekatan evaluasi cross-dataset yang secara sistematis menguji model-model yang dikembangkan pada CICIoT2023 terhadap dataset DataSense (CIC IIoT 2025).

Kerangka evaluasi yang diajukan memiliki beberapa keunggulan unik. Pertama, penelitian ini merupakan studi pertama yang secara eksplisit mengukur generalization gap antara domain IoT konsumen (CICIoT2023) dan domain IIoT industri (DataSense), sehingga menghasilkan pemahaman kuantitatif tentang seberapa jauh model yang bekerja baik secara in-dataset mampu bertahan di lingkungan yang berbeda. Kedua, evaluasi dilakukan secara komparatif terhadap tiga algoritma dengan tingkat kompleksitas ensemble yang berbeda Decision Tree (model pohon tunggal yang interpretable), Random Forest (ensemble bagging), dan XGBoost (ensemble boosting) sehingga menghasilkan gambaran tentang bagaimana peningkatan kompleksitas ensemble memengaruhi kemampuan generalisasi lintas domain. Ketiga, penelitian ini menganalisis ketahanan fitur (feature robustness) secara lintas domain dengan mengidentifikasi subset fitur dari CICIoT2023 yang mempertahankan daya prediktif ketika diterapkan pada DataSense. Keempat, hasil penelitian dikemas sebagai rekomendasi praktis yang dapat digunakan oleh peneliti yang ingin menjadikan DataSense sebagai titik awal pengembangan sistem IDS berbasis ML untuk lingkungan IIoT.

1.4 MANFAAT

Penelitian ini memberikan kontribusi yang dapat dirasakan oleh beberapa pihak. Bagi komunitas riset keamanan jaringan IoT/IIoT, penelitian ini mengisi celah literatur yang selama ini belum ditangani, yaitu studi cross-dataset yang mengukur kemampuan generalisasi model IDS dari domain IoT konsumen ke domain IIoT industri. Hasil evaluasi kuantitatif yang dihasilkan dapat menjadi referensi dalam perancangan eksperimen penelitian sejenis di masa mendatang.

Bagi peneliti yang ingin bekerja dengan dataset DataSense (CIC IIoT 2025), penelitian ini berfungsi sebagai foundational reference menyediakan pemahaman awal tentang karakteristik dataset, distribusi kelas, dan performa baseline berbagai algoritma, sehingga peneliti berikutnya tidak perlu memulai dari nol. Bagi praktisi dan pengembang sistem keamanan IoT/IIoT, penelitian ini memberikan panduan empiris tentang keluarga algoritma dan konfigurasi fitur yang paling layak dipertimbangkan untuk skenario deployment lintas domain, sekaligus mengingatkan risiko overfitting terhadap karakteristik satu dataset spesifik yang kerap terjadi dalam pengembangan IDS berbasis ML.

1.5 SISTEMATIKA PENULISAN

Adapun sistematika penulisan untuk Proposal Buku Proyek Akhir ini adalah:

Bab 1

Pendahuluan

Bab ini menguraikan latar belakang permasalahan terkait meningkatnya ancaman serangan siber pada jaringan IoT dan IIoT serta keterbatasan pendekatan Intrusion Detection System (IDS) konvensional dalam menghadapinya. Di dalam bab ini juga dirumuskan pertanyaan penelitian, tujuan utama yang ingin dicapai, serta batasan masalah agar pengembangan sistem deteksi intrusi berbasis machine learning ini lebih terarah. Selain itu, bagian ini menjabarkan manfaat penelitian secara praktis maupun teoretis, sekaligus memberikan gambaran umum mengenai sistematika penulisan laporan dari awal hingga akhir.

Bab 2

Kajian Pustaka

Bab ini membahas landasan teoretis yang menjadi fondasi utama dalam pengembangan sistem, meliputi konsep dasar IoT dan IIoT, karakteristik ancaman keamanan jaringan, serta prinsip kerja Intrusion Detection System berbasis anomali. Pembahasan teknis juga diuraikan secara mendalam, mencakup algoritma-algoritma machine learning yang digunakan seperti Decision Tree, Random Forest, k-NN, Naive Bayes, SVM, dan Logistic Regression, beserta karakteristik dataset CICIoT2023 sebagai sumber data penelitian. Selain itu, bab ini memuat tinjauan terhadap berbagai penelitian terdahulu yang relevan untuk menunjukkan posisi kebaruan serta memperkuat argumen ilmiah dari pendekatan yang diusulkan.

Bab 3

Desain Sistem

Bab ini memaparkan rancangan alur penelitian secara komprehensif, mulai dari tahap pengumpulan dan eksplorasi data, prapemrosesan, seleksi fitur, pelatihan model, hingga evaluasi performa. Penjelasan mendetail diberikan mengenai setiap tahapan eksperimen, termasuk strategi penanganan ketidakseimbangan kelas, teknik validasi yang diterapkan, serta metrik evaluasi yang digunakan seperti akurasi, presisi, recall, dan F1-score. Pada bagian akhir bab ini juga dijabarkan lingkungan pengujian dan konfigurasi eksperimen yang menjadi acuan dalam proses implementasi.

BAB. II

KAJIAN PUSTAKA

2.1 DESKRIPSI PERMASALAHAN

Perkembangan ekosistem Internet of Things (IoT) dan Industrial Internet of Things (IIoT) menghadirkan tantangan keamanan yang fundamental. Perangkat IoT umumnya bersifat resource-constrained memiliki daya komputasi, memori, dan kapasitas baterai yang terbatas, sehingga mekanisme keamanan konvensional yang dirancang untuk sistem komputasi umum tidak dapat diterapkan secara langsung [3], [11]. Di sisi IIoT, lingkungan industri menambahkan lapisan kompleksitas berupa heterogenitas perangkat, campuran protokol komunikasi yang sebagian terstandarisasi dan sebagian proprietary, serta tuntutan ketersediaan layanan yang tidak boleh terganggu oleh proses deteksi ancaman [1].

Permasalahan utama yang dihadapi dalam penelitian ini adalah kesenjangan generalisasi model deteksi intrusi lintas domain. Model machine learning yang dilatih dan diuji pada dataset IoT konsumen (CICIoT2023) kerap menunjukkan akurasi tinggi secara in-dataset, namun belum terbukti mampu mempertahankan performa yang setara ketika diterapkan pada lingkungan IIoT industri yang berbeda secara statistik maupun operasional. Perbedaan jenis perangkat, topologi jaringan, distribusi kelas serangan, dan karakteristik trafik antara kedua domain berpotensi menyebabkan domain shift yang signifikan sehingga menurunkan kemampuan generalisasi model [1], [2].

Secara konkret, CICIoT2023 mencakup 33 jenis serangan yang dibangkitkan oleh 105 perangkat IoT konsumen dalam topologi terkontrol dengan lebih dari 46 juta rekaman dan 48 fitur jaringan [2], [11]. Sementara itu, DataSense (CIC IIoT 2025) mencakup 50 skenario serangan pada sensor industri berbasis Arduino dan perangkat IoT komersial yang terhubung melalui MQTT broker, dengan data sensor yang tersinkronisasi dengan data trafik jaringan dalam pendekatan multi-objective feature selection [1]. Kombinasi perbedaan skala, ruang fitur, dan karakteristik domain ini menjadikan evaluasi cross-dataset sebagai tantangan teknis yang perlu dikaji secara sistematis.

2.2 TEORI PENUNJANG

2.2.1 Internet of Things (IoT)

Internet of Things (IoT) adalah paradigma jaringan yang menghubungkan perangkat fisik maupun virtual, sensor, aktuator, kamera, dan berbagai perangkat cerdas lainnya — ke internet, memungkinkan komunikasi mesin-ke-mesin (M2M) tanpa intervensi manusia [3], [11]. Konsep ini sudah diterapkan luas di berbagai sektor, mulai dari pertanian, rumah tangga pintar, layanan kesehatan, transportasi, hingga otomasi industri [3], [4]. Menurut Dzaki et al. [11], pada akhir tahun 2020 terdapat 11,3 miliar perangkat IoT yang terhubung dan diperkirakan akan mencapai 27,1 miliar pada tahun 2025, didorong oleh kemudahan pengumpulan data dan otomasi proses yang ditawarkan teknologi ini.

Karakteristik utama perangkat IoT yang membedakannya dari perangkat komputasi konvensional adalah keterbatasan sumber daya: kapasitas penyimpanan rendah, daya komputasi terbatas, dan konsumsi energi minimal [3], [11]. Menurut Alsamiri dan Alsubhi

[3], perangkat IoT umumnya terhubung tanpa intervensi manusia dalam jangka waktu panjang, sehingga dibutuhkan solusi keamanan berbasis jaringan yang cerdas — bukan solusi konvensional berkapasitas tinggi yang tidak cocok untuk lingkungan IoT. Perluasan ekosistem IoT inilah yang sekaligus memperbesar attack surface bagi pelaku ancaman siber.

2.2.2 Industrial Internet of Things (IIoT)

Industrial Internet of Things (IIoT) merupakan perluasan konsep IoT pada lingkungan industri, mengintegrasikan sensor industri, mesin, dan infrastruktur jaringan untuk mengoptimalkan proses produksi serta mendukung pengambilan keputusan berbasis data secara real-time [1]. Firouzi et al. [1] menjabarkan penerapan IIoT di berbagai sektor kritis:

2.2.3 Intrusion Detection System (IDS)

Intrusion Detection System (IDS) adalah mekanisme pengawasan jaringan yang secara otomatis menganalisis trafik untuk mengidentifikasi aktivitas mencurigakan atau berbahaya yang berpotensi mengancam keamanan sistem. Secara umum, IDS diklasifikasikan ke dalam dua kategori utama berdasarkan pendekatan deteksinya: signature-based detection dan anomaly-based detection [16]. Signature-based IDS bekerja dengan mencocokkan pola trafik terhadap basis data signature serangan yang telah diketahui; pendekatan ini efektif untuk serangan terdokumentasi namun tidak mampu mendeteksi serangan zero-day yang belum memiliki signature. Sebaliknya, anomaly-based IDS membangun model perilaku trafik normal dan menandai setiap deviasi signifikan sebagai potensi ancaman, sehingga secara teoritis mampu mendeteksi serangan yang belum pernah ditemui sebelumnya [16].

Perkembangan machine learning telah mendorong pergeseran paradigma IDS dari pendekatan berbasis aturan ke pendekatan berbasis data. Saheed et al. [9] menegaskan bahwa algoritma machine learning mampu mempelajari pola trafik secara otomatis dari data historis dan menghasilkan model klasifikasi yang dapat membedakan trafik normal dari trafik serangan dengan akurasi kompetitif. Gutierrez [16] mengkonfirmasi bahwa IDS berbasis ML menjadi komponen fundamental dalam proteksi infrastruktur kritis karena kemampuannya menangani spektrum ancaman yang lebih luas dibandingkan sistem berbasis signature. Dalam konteks IoT dan IIoT, kebutuhan akan IDS berbasis ML semakin mendesak karena keterbatasan sumber daya perangkat dan heterogenitas protokol komunikasi membuat solusi keamanan konvensional tidak dapat diterapkan secara efektif [3], [7].

2.2.4 Decision Tree

Decision Tree (DT) adalah algoritma pembelajaran terawasi non-parametrik yang membangun model klasifikasi dalam bentuk struktur pohon hierarkis, di mana setiap simpul internal merepresentasikan pengujian terhadap suatu atribut fitur, setiap cabang merepresentasikan hasil pengujian, dan setiap simpul daun (leaf) merepresentasikan label kelas [11]. Proses pembangunan pohon dilakukan secara rekursif menggunakan kriteria impuritas untuk memilih fitur pemisah terbaik di setiap langkah; dua kriteria yang paling umum digunakan adalah Gini Impurity dan Information Gain. Gini Impurity mengukur

seberapa sering sampel yang dipilih secara acak dari suatu himpunan akan salah diklasifikasikan jika diberi label sesuai distribusi kelas pada himpunan tersebut, sehingga DT memilih pemisahan yang meminimalkan nilai Gini Impurity pada setiap simpul [11].

Karakteristik utama DT yang membuatnya relevan dalam konteks IDS adalah sifatnya yang sepenuhnya interpretable — setiap keputusan klasifikasi dapat dilacak kembali ke serangkaian aturan kondisional yang dapat dibaca manusia. Dzaki et al. [11] membuktikan bahwa DT dengan seleksi fitur berbasis Gini Impurity Tree-based berhasil mereduksi 48 fitur CICIOT2023 menjadi 10 fitur terpilih, menghasilkan pohon yang lebih dangkal (64 level dari 73 level baseline) dengan percepatan pelatihan 63,06% tanpa penurunan akurasi yang berarti. Dalam penelitian ini, DT difungsikan sebagai model baseline pohon tunggal yang menghasilkan batas keputusan eksplisit sekaligus sebagai fondasi komparatif terhadap algoritma ensemble yang lebih kompleks.

2.2.5 Random forest

Random Forest (RF) adalah algoritma ensemble berbasis bagging yang membangun sejumlah pohon keputusan secara paralel, masing-masing dilatih pada subset data dan subset fitur yang dipilih secara acak, kemudian menggabungkan prediksi seluruh pohon melalui mekanisme majority voting untuk menghasilkan keputusan akhir [4]. Pengacakan ganda — pada level sampel data (bootstrap sampling) maupun pada level pemilihan fitur di setiap simpul (random feature subspace) — mereduksi korelasi antar pohon secara signifikan sehingga meningkatkan generalisasi model dan mengurangi risiko overfitting dibandingkan pohon keputusan tunggal. Sebagai efek samping dari proses pelatihan berbasis pohon, RF juga menghasilkan feature importance score yang dapat dimanfaatkan untuk seleksi fitur dalam pipeline IDS [10].

Dalam literatur IDS berbasis machine learning, Random Forest secara konsisten muncul sebagai model dengan performa tertinggi. Ntayagabiri et al. [8] melaporkan bahwa RF mencapai akurasi 99,29% pada CICIOT2023, melampaui seluruh model non-ensemble maupun deep learning yang dievaluasi. Premalatha dan Ramanujam [15] mengkonfirmasi dominansi RF dalam studi serupa pada dataset yang sama. Firdaus et al. [10] memanfaatkan Random Forest Feature Importance (RFFI) sebagai komponen dalam seleksi fitur hibrida, menunjukkan bahwa RF tidak hanya unggul sebagai model klasifikasi tetapi juga berperan dalam tahap seleksi fitur pada pipeline IDS secara keseluruhan.

2.2.6 Support Vector Machine (SVM)

Support Vector Machine (SVM) adalah algoritma pembelajaran terawasi yang bekerja dengan menemukan hyperplane optimal dalam ruang fitur berdimensi tinggi yang memisahkan kelas-kelas dengan margin maksimum [10]. Untuk data yang tidak dapat dipisahkan secara linear, SVM menggunakan fungsi kernel — seperti kernel RBF (Radial Basis Function), polynomial, atau sigmoid — untuk memetakan data ke ruang dimensi lebih tinggi di mana pemisahan linear menjadi dimungkinkan [17]. Konsep margin maksimum inilah yang memberikan SVM sifat generalisasi yang baik secara teoritis, karena hyperplane

yang dipilih adalah yang paling jauh dari titik data terdekat dari masing-masing kelas (support vectors).

Vassiliou [17] mengevaluasi dua varian SVM — C-SVM dan OC-SVM — untuk deteksi serangan jaringan pada perangkat IoT berdaya rendah dan menemukan bahwa C-SVM mencapai akurasi 100% pada topologi jaringan yang dikenal, namun menurun menjadi 81% pada topologi yang belum pernah dilihat sebelumnya, mengindikasikan sensitivitas SVM terhadap pergeseran distribusi data. Firdaus et al. [10] mengevaluasi SVM dalam komparasi dengan model ensemble pada CICIOT2023 dan menemukan bahwa performa SVM sangat bergantung pada kualitas preprocessing — khususnya normalisasi fitur — karena sensitivitasnya terhadap skala fitur dalam perhitungan jarak kernel. Karakteristik ini menjadikan SVM sebagai algoritma yang relevan untuk dikaji dalam skenario cross-dataset, di mana konsistensi distribusi fitur lintas domain menjadi faktor penentu.

2.3 PENELITIAN TERKAIT

2.3.1 A Comparative Analysis of Supervised Machine Learning Algorithms for IoT Attack Detection and Classification [8]

Ntayagabiri et al. [8] melakukan analisis komparatif sepuluh algoritma supervised learning pada dataset CICIOT2023, mencakup tiga keluarga model: algoritma klasik (Naive Bayes, Logistic Regression, k-NN), ensemble (Random Forest, XGBoost, LightGBM), dan deep learning (ANN, CNN, LSTM, GRU). Random Forest mencapai akurasi tertinggi sebesar 99,29% dengan presisi 82,30%, diikuti XGBoost sebesar 99,26%. Di antara model deep learning, CNN unggul dengan akurasi 98,33%, sementara LSTM dan GRU masing-masing mencapai 97,60% dan 96,87%. Penelitian ini menyoroti bahwa nilai recall yang bervariasi antar algoritma — Random Forest 72,19%, XGBoost 71,69%, CNN 64,72% — mengindikasikan bahwa akurasi agregat yang tinggi belum tentu mencerminkan kemampuan deteksi yang merata pada seluruh kelas serangan, terutama kelas minoritas. Seluruh evaluasi dilakukan secara in-dataset pada CICIOT2023 tanpa pengujian lintas domain.

2.3.2 Evaluating Ensemble Versus Non-Ensemble Machine Learning Performance with Preprocessing Techniques for IoT Intrusion Detection on CICIOT2023

Firdaus et al. [10] mengevaluasi performa model ensemble dibandingkan non-ensemble dengan penekanan pada peran teknik preprocessing dalam meningkatkan stabilitas model pada CICIOT2023. Penelitian ini menerapkan random undersampling untuk mengatasi ketidakseimbangan kelas yang ekstrem, dikombinasikan dengan seleksi fitur hibrida yang memadukan Mutual Information (MI) dan Random Forest Feature Importance (RFFI). Lima model diuji — Naive Bayes, Logistic Regression, SVM, Random Forest, dan XGBoost — menggunakan stratified 5-fold cross-validation. XGBoost tampil sebagai model terbaik dengan macro F1-score rata-rata $0,8891 \pm 0,0008$. Kontribusi penting penelitian ini adalah pembuktian kuantitatif bahwa normalisasi bukan langkah opsional: Logistic Regression tanpa

scaling menghasilkan F1-score tidak stabil sebesar 0,6280, namun melonjak menjadi 0,7691 setelah normalisasi Min-Max diterapkan. Sama seperti penelitian sebelumnya, eksperimen dilakukan sepenuhnya pada satu domain dataset yang sama.

2.3.3 Accelerating Classification for IoT Attack Detection Using Decision Tree Model with Gini Impurity Tree-Based Feature Selection Technique

Dzaki et al. [11] mengembangkan pendekatan akselerasi klasifikasi serangan IoT berbasis seleksi fitur Gini Impurity Tree-based pada CICIoT2023. Penelitian ini membandingkan enam teknik seleksi fitur dari tiga kategori — filter (Fisher Score, Mutual Information), wrapper (Recursive Feature Elimination, Genetic Algorithm), dan embedded (Gini Impurity Tree-based, Lasso-based). Gini Impurity Tree-based terbukti paling efisien: menghasilkan subset 10 fitur dengan waktu pemrosesan hanya 40 detik, mempercepat pelatihan sebesar 63,06% dibandingkan baseline 48 fitur, dan menghasilkan pohon keputusan lebih dangkal (64 level dari 73 level) — semua tanpa penurunan akurasi yang berarti. Penelitian ini memfokuskan kontribusinya pada efisiensi komputasi dalam satu dataset, tanpa mengkaji apakah subset fitur yang dipilih bersifat robust ketika diterapkan pada domain dataset yang berbeda.

Ketiga penelitian di atas secara konsisten menghasilkan model dengan performa tinggi pada CICIoT2023, namun seluruhnya hanya melakukan evaluasi in-dataset. Tidak ada satu pun yang menguji apakah model atau fitur yang dihasilkan mampu mempertahankan performa ketika diterapkan pada domain IIoT industri yang berbeda secara statistik maupun operasional. Celah inilah yang menjadi motivasi penelitian ini: mengevaluasi kemampuan generalisasi cross-dataset dari model-model yang dikembangkan pada CICIoT2023 terhadap DataSense (CIC IIoT 2025), sekaligus mengidentifikasi fitur yang paling robust lintas kedua domain.

Tabel 2. 2 Gap Penelitian

Judul Penelitian	Tahun	Dataset	Metode yang Digunakan	Metode yang digunakan	Gap & Keterbatasan dalam Konteks Generasi Narasi Laporan
[8]	2025	CICIoT2023	Multiclass	RF, XGBoost, LightGBM, CNN, LSTM, dll.	In-dataset only; recall rendah (72.19%); tidak uji generalisasi ke IIoT
[11]	2025	CICIoT2023	Multiclass	DT + Gini Impurity FS	In-dataset only; 10 fitur terpilih tidak divalidasi di dataset lain; robustness fitur lintas domain tidak dieksplorasi
[13]	2025	CICIoT2023	Multiclass	SOM + DBN + Autoencoder + PSO	In-dataset only; arsitektur DL berat tidak cocok edge IoT; tidak ada cross-dataset
[22]	2026	CICIoT2025	Binary	CNN-BiLSTM + Permutation Importance	Binary only — tidak uji multiclass; in-dataset DataSense only; tidak ada evaluasi model dari CICIoT2023 ke DataSense

BAB. III DESAIN SISTEM

3.1 DESKRIPSI SOLUSI


Penelitian ini mengajukan kerangka evaluasi cross-dataset sebagai solusi terhadap permasalahan yang belum banyak diteliti dalam literatur: sejauh mana model intrusion detection berbasis machine learning yang dilatih pada dataset IoT konsumen (CICIoT2023) mampu mempertahankan performanya ketika diterapkan pada lingkungan IIoT industri (DataSense). Berbeda dari penelitian terdahulu yang mengevaluasi model dalam satu domain dataset yang sama, kerangka ini secara eksplisit mengukur generalization gap — selisih performa model antara evaluasi in-dataset dan evaluasi lintas domain — sebagai luaran analitik utamanya.

Tiga algoritma dipilih untuk merepresentasikan spektrum kompleksitas ensemble yang berbeda: Decision Tree sebagai model pohon tunggal yang sepenuhnya interpretable, Random Forest sebagai ensemble berbasis bagging, dan XGBoost sebagai ensemble berbasis boosting sekuensial. Pemilihan ini didukung oleh konsistensi performa ketiganya dalam literatur terkait, di mana Random Forest muncul sebagai top performer di sebagian besar studi [4][8][15], XGBoost mengungguli seluruh model dalam macro F1-score pada dua studi berbasis CICIoT2023 [8][10], dan Decision Tree terbukti paling efisien dengan akurasi 98,34% serta waktu seleksi fitur tercepat [5][11]. Dengan membandingkan ketiga algoritma pada level kompleksitas yang berbeda, penelitian ini dapat menjawab apakah kompleksitas ensemble memberikan keunggulan tambahan saat model harus digeneralisasikan ke domain baru.

Data CICIoT2023 diproses melalui pipeline empat tahap secara berurutan: data cleaning untuk menghapus duplikat dan nilai hilang, random undersampling untuk menyeimbangkan distribusi kelas [10][11], Gini Impurity Tree-based feature selection untuk mereduksi 48 fitur menjadi subset minimal [11], dan Min-Max normalization ke rentang [0,1] sebagai prasyarat konsistensi skala fitur lintas domain [10][11]. Evaluasi lintas domain dilakukan dengan membangun interseksi fitur — hanya fitur yang tersedia di kedua dataset yang dipertahankan sebagai input model — sekaligus menyelaraskan label ke lima kelas bersama yang ada di kedua domain: DDoS, DoS, Reconnaissance, Brute Force, dan Benign. Generalization gap dihitung sebagai selisih Macro F1 antara evaluasi in-dataset dan cross-dataset untuk masing-masing algoritma, sehingga model dengan degradasi performa terkecil dapat diidentifikasi sebagai algoritma paling robust untuk skenario deteksi lintas domain IoT ke IIoT.

3.2 DESAIN SISTEM

Desain sistem dari kerangka evaluasi cross-dataset yang diajukan diilustrasikan pada Gambar 3.1. Sistem terdiri dari dua pipeline paralel yang berasal dari dua sumber data berbeda — CICIoT2023 sebagai domain IoT konsumen dan DataSense (CIC IIoT 2025) sebagai domain IIoT industri — yang keduanya bermuara pada satu node evaluasi bersama.



Gambar 3.1.
Desain sistem kerangka evaluasi cross-dataset IoT-IIoT

Secara garis besar, pipeline CICIOT2023 mengalirkan data melalui tahap pemrosesan data, seleksi fitur, dan pelatihan model menggunakan tiga algoritma ML. Model yang telah terlatih kemudian diuji secara bersamaan pada test set CICIOT2023 (evaluasi in-dataset) dan pada DataSense yang telah menjalani pemrosesan dan penyelarasan fitur secara paralel (evaluasi cross-dataset). Node cross dataset evaluation menghasilkan laporan generalization gap yang menjadi keluaran utama penelitian. Umpan balik dari node evaluasi ke tahap seleksi fitur DataSense menunjukkan bahwa analisis fitur mana yang robust lintas domain menginformasikan pemahaman karakteristik DataSense secara iteratif.

3.2.1 Dataset

3.2.1.1 CIC IoT 2023



Gambar 3. 2 *Preview Pedoman Penyusunan LED*

Instrumen Pedoman Penyusunan laporan evaluasi diri (LED) merupakan salah satu sumber pengetahuan utama yang digunakan dalam penelitian ini. Dokumen yang digunakan adalah Pedoman Penyusunan Laporan Evaluasi Diri Akreditasi Program Studi Vokasi, Akademik, dan Program Profesi Insinyur Tahun 2025 yang diterbitkan oleh LAM Teknik [4]. Dokumen ini berfungsi sebagai acuan utama dalam penyusunan narasi LED karena memuat struktur laporan, tujuan evaluasi diri, mekanisme penyusunan, kriteria akreditasi, indikator yang harus dibahas, serta bentuk analisis yang diharapkan dalam setiap bagian laporan. Pedoman ini memiliki struktur dokumen yang hierarkis dan terorganisasi dengan baik, dimulai dari tingkat bab, subbab, hingga rincian indikator pada masing-masing kriteria akreditasi. Struktur tersebut menjadi landasan penting dalam proses generasi narasi karena menentukan informasi apa saja yang perlu disampaikan pada setiap bagian LED.

Tabel 3. 1 Metadata Hasil *Preprocessing* Pedoman Penulisan LED

Nama Metadata	Tipe Data	Deskripsi
bab	String	Bab utama tempat informasi berada.
sub_bab	String	Subbab yang menjadi bagian dari bab utama.
sub_sub_bab	String	Subbagian yang lebih spesifik dari subbab.
list	String	Penanda daftar atau poin pada dokumen.
konten	String	Berisi konten yang diambil pada segmen tersebut.

Metadata yang ditampilkan pada Tabel 3.1 menampilkan setiap segmen yang digunakan untuk mempertahankan struktur semantik dokumen pedoman selama proses pengolahan data. Setiap atribut merepresentasikan hierarki pembahasan, sedangkan atribut list menunjukkan keterkaitan antarbutir informasi pada dokumen. Berdasarkan proses ekstraksi yang dilakukan, dokumen Pedoman Penyusunan Laporan Evaluasi Diri menghasilkan sebanyak 69 butir instrumen yang selanjutnya digunakan sebagai sumber pengetahuan dalam proses *retrieval* pada sistem RAG.

3.2.1.2 CIC Iot 2025

[illegible]

Gambar 3. 3 *Preview* Matriks Penilaian LED

Matriks penilaian laporan evaluasi diri (LED merupakan salah satu sumber pengetahuan utama yang digunakan dalam penelitian ini. Dokumen yang digunakan adalah Matriks Penilaian Laporan Evaluasi Diri dan Laporan Kinerja Program Studi Program Sarjana Terapan APS-AV 2025 yang diterbitkan oleh LAM Teknik [39] . Dokumen ini berfungsi sebagai instrumen evaluasi yang menjelaskan kriteria penilaian, indikator yang dinilai, serta deskripsi capaian pada setiap tingkat skor. Berbeda dengan pedoman penyusunan LED yang berfokus pada tata cara penyusunan laporan, matriks penilaian digunakan untuk mengidentifikasi aspek-aspek yang menjadi perhatian asesor dalam proses akreditasi sehingga sistem dapat menghasilkan narasi yang tidak hanya sesuai format, tetapi juga berorientasi pada pencapaian skor yang optimal. Karakteristik utama dokumen ini adalah penyajiannya dalam bentuk tabel penilaian yang terstruktur. Setiap tabel memuat informasi mengenai kriteria, indikator, serta deskripsi capaian untuk skor 4 hingga 0. Struktur data yang dominan berupa tabel menyebabkan proses ekstraksi dilakukan menggunakan skema yang berbeda dibandingkan dokumen naratif. Setiap baris tabel diekstraksi menjadi unit informasi yang mempertahankan hubungan antara kriteria, indikator, dan deskripsi penilaian sehingga konteks penilaian tetap terjaga selama proses *retrieval*.

Tabel 3. 2 Metadata Hasil *Preprocessing* Matriks Penilaian LED

Nama Metadata	Tipe Data	Deskripsi
bab	String	Kelompok kriteria utama penilaian.
sub	String	Subkriteria atau kategori penilaian.
sub_sub	String	Subbagian penilaian yang lebih spesifik.
kriteria	String	Nama indikator atau aspek yang dinilai.
konten	String	Berisi konten yang diambil pada segmen tersebut.

Metadata yang ditampilkan pada Tabel 3.2 digunakan untuk mempertahankan struktur semantik hasil ekstraksi dari dokumen matriks. Atribut bab, subb, dan sub_sub merepresentasikan hierarki kriteria penilaian, sedangkan atribut kriteria menyimpan nama indikator atau aspek yang dievaluasi. Seluruh metadata tersebut kemudian dilinearisasi bersama atribut konten menjadi representasi teks yang digunakan pada proses pembentukan embedding. Pendekatan ini memungkinkan sistem memahami keterkaitan antara indikator penilaian dan deskripsi capaian skor yang menyertainya. Berdasarkan proses ekstraksi yang dilakukan, dokumen matriks penilaian menghasilkan sebanyak 64 instrumen penilaian yang digunakan sebagai sumber pengetahuan pada proses retrieval. Instrumen-instrumen tersebut merepresentasikan berbagai aspek evaluasi akreditasi yang tersebar pada beberapa kriteria utama, sehingga memungkinkan sistem menghasilkan narasi LED yang lebih selaras dengan indikator penilaian yang digunakan oleh asesor.

3.2.2 Data Preprocessing

Pemrosesan data merupakan tahap pertama pada kedua pipeline dan bertujuan mengubah data mentah dari masing-masing dataset ke bentuk yang siap diproses model ML.

Pada pipeline CICIOT2023, pemrosesan data mencakup empat langkah berurutan. Pertama, data cleaning: menghapus baris duplikat, menangani nilai hilang (missing values) dengan strategi drop-row, dan menghapus fitur non-informatif seperti alamat IP sumber/tujuan, nomor port, dan timestamp yang tidak berkontribusi pada deteksi pola serangan. Kedua, random undersampling: mendistribusikan ulang kelas dengan mengambil sejumlah sampel yang sama dari setiap kelas — mengacu pada distribusi Dzaki et al. [11] yang menggunakan 437.853 sampel per kelas untuk 8 kelas, menurunkan total data dari 46 juta baris menjadi sekitar 3,5 juta baris. Ketiga, Gini Impurity Tree-based feature selection: memilih subset fitur paling relevan dari 48 fitur awal menggunakan algoritma Decision Tree dengan kriteria Gini Impurity, menghasilkan 10

fitur terpilih [11]. Keempat, Min-Max normalization: menskalakan semua nilai fitur ke rentang $[0,1]$ menggunakan parameter minimum dan maksimum yang dihitung eksklusif dari data training.

Pada pipeline DataSense, pemrosesan data mengikuti langkah yang serupa dalam hal cleaning dan normalisasi, namun tidak melibatkan undersampling karena DataSense digunakan seluruhnya sebagai test set. Parameter normalisasi (nilai min dan max per fitur) yang digunakan adalah parameter yang sama yang dihitung dari data training CICIOT2023 — bukan dihitung ulang dari DataSense — untuk memastikan konsistensi transformasi lintas domain dan menghindari kebocoran informasi dari test set ke training.

3.2.3 Seleksi Fitur dan Penyelarasan Domain

Setelah tahap preprocessing, seleksi fitur pada pipeline CICIOT2023 menghasilkan subset fitur terpilih yang kemudian dicocokkan dengan fitur yang tersedia di DataSense melalui proses feature alignment.

Feature alignment dilakukan dengan membangun interseksi fitur — hanya fitur yang secara eksplisit tersedia di kedua CICIOT2023 dan DataSense yang dipertahankan sebagai input model saat evaluasi cross-dataset. Fitur CICIOT2023 yang tidak memiliki padanan semantik di DataSense dieliminasi dari pipeline evaluasi lintas domain. Jumlah fitur dalam interseksi ini menjadi salah satu variabel analisis utama: semakin kecil interseksi relatif terhadap jumlah fitur awal, semakin besar perbedaan ruang fitur yang harus dihadapi model.

Penyelarasan label kelas dilakukan bersamaan dengan penyelarasan fitur. Delapan kelas CICIOT2023, DDoS, DoS, Mirai, Benign, Spoofing, Recon, Web, dan Brute Force dipetakan ke lima kelas bersama yang tersedia di kedua dataset: DDoS, DoS, Reconnaissance, Brute Force, dan Benign. Kelas Mirai, Spoofing, dan Web-based pada CICIOT2023, serta kelas Man-in-the-Middle dan Malware pada DataSense, dieliminasi dari evaluasi cross-dataset karena tidak memiliki padanan langsung di dataset yang berlawanan. Pemetaan ini memastikan bahwa perbandingan performa model antar domain dilakukan pada basis kelas yang identik.

3.2.4 Pelatihan Model dan Evaluasi Cross-Dataset

Pelatihan model dilakukan pada data CICIOT2023 yang telah melewati seluruh tahap preprocessing dan seleksi fitur. Data CICIOT2023 yang telah bersih dibagi menggunakan stratified split 80:20, di mana 80% digunakan untuk training dan 20% digunakan untuk evaluasi in-dataset. Stratified split diterapkan untuk memastikan distribusi kelas yang proporsional di kedua partisi, mengingat data yang dipakai telah melalui random undersampling namun tetap perlu dijaga konsistensi distribusi kelasnya.

Tiga model dilatih secara independen menggunakan data training yang sama. Decision Tree dilatih dengan kriteria Gini Impurity sebagai model baseline pohon tunggal yang menghasilkan aturan klasifikasi yang sepenuhnya interpretable. Random Forest dilatih menggunakan

mekanisme bootstrap aggregating di mana sejumlah pohon keputusan dibangun secara paralel pada subset data dan fitur yang berbeda, kemudian prediksi digabung melalui majority voting. XGBoost dilatih menggunakan gradient boosting sekuensial dengan regularisasi L1 dan L2 bawaan untuk mencegah overfitting, di mana setiap pohon baru difokuskan memperbaiki kesalahan residual model sebelumnya.

Evaluasi dilakukan dalam dua tahap yang menghasilkan dua set metrik berbeda. Evaluasi in-dataset mengaplikasikan ketiga model yang telah terlatih pada 20% test set CICIOT2023 untuk menghasilkan Macro F1, Accuracy, dan Recall per kelas pada domain asal ($F1_{in}$, Acc_{in} , Rec_{in}). Evaluasi cross-dataset mengaplikasikan model yang sama — tanpa modifikasi atau retraining apapun — pada seluruh DataSense yang telah diselaraskan fitur dan kelasnya, menghasilkan metrik yang setara pada domain target ($F1_{cross}$, Acc_{cross} , Rec_{cross}).

$$\Delta Macro F1 = F1_{in} - F1_{cross}$$

Nilai Δ Macro F1 yang mendekati nol mengindikasikan kemampuan generalisasi yang tinggi, sementara nilai yang besar mengindikasikan adanya domain shift yang signifikan antara CICIOT2023 dan DataSense. Persamaan 3.1 dihitung untuk ketiga model secara terpisah, sehingga menghasilkan perbandingan langsung antara Decision Tree, Random Forest, dan XGBoost dalam hal ketahanan terhadap pergeseran domain. Model dengan Δ Macro F1 terkecil ditetapkan sebagai algoritma yang paling robust untuk skenario evaluasi lintas domain IoT ke IIoT.

-

3.3 Timeline Pengerjaan

Tabel 3. 1 Rancangan Timeline Pengerjaan Proyek Akhir

Kegiatan	Jul 26	Agu 26	Sep 26	Okt 26	Nov 26	Des 26	Jan 27	Feb 27	Mar 27	Apr 27	Mei 27	Jun 27	Jul 27
• Penyusunan metodologi dan rancangan eksperimen													
• Persiapan, cleaning, dan preprocessing data CIC IoT 2023													
• Persiapan, cleaning, dan preprocessing data CIC IoT 2025													
• Integrasi data, feature engineering, dan penyiapan skenario eksperimen													
• Implementasi baseline dan model utama													
• Evaluasi, tuning, dan analisis hasil													
• Pengujian & Evaluasi Sistem													

DAFTAR PUSTAKA

- [1] Firouzi, A., Dadkhah, S., Maret, S. A., Ghorbani, A. A., DataSense: A Real-Time Sensor-Based Benchmark Dataset for Attack Analysis in IIoT with Multi-Objective Feature Selection, *Electronics*, Vol. 14, No. 20, Art. No. 4095, 2025.
- [2] Neto, E. C. P., Dadkhah, S., Ferreira, R., Zohourian, A., Lu, R., Ghorbani, A. A., CIIoT2023: A Real-Time Dataset and Benchmark for Large-Scale Attacks in IoT Environment, *Sensors*, Vol. 23, No. 13, Art. No. 5941, 2023.
- [3] Alsamiri, J., Alsubhi, K., Internet of Things Cyber Attacks Detection Using Machine Learning, *International Journal of Advanced Computer Science and Applications (IJACSA)*, Vol. 10, No. 12, 2019.
- [4] Churcher, A., Razdan, R., Ahmad, I., Tachtatzis, C., Sherwood, D., Weir, G., Andonovic, I., Michie, C., Tan, W. S., An Experimental Analysis of Attack Classification Using Machine Learning in IoT Networks, *Sensors*, Vol. 21, No. 2, Art. No. 446, 2021.
- [5] Abebe, A., Gebeyehu, S., Alem, A., Internet of Things Attack Detection Using Machine Learning Algorithms, *F1000Research*, Vol. 14, Art. No. 230, 2026.
- [6] Bzai, J., Alam, F., Dhafer, A., Bojovic, M., Altowaijri, S. M., Niazi, I. K., Mehmood, R., Machine Learning-Enabled Internet of Things (IoT): Data, Applications, and Industry Perspective, *Electronics*, Vol. 11, No. 17, Art. No. 2676, 2022.
- [7] Blali, A., Dargaoui, S., Azrour, M., Guezzaz, A., Amounas, F., Alabdulatif, A., Analysis of Deep Learning-Based Intrusion Detection Systems in IoT Environments, *EDPACS*, Vol. 70, No. 11, Hal. 18–52, 2025.
- [8] Ntayagabiri, J. P., Bentaleb, Y., Ndikumagenge, J., El Makhtoum, H., A Comparative Analysis of Supervised Machine Learning Algorithms for IoT Attack Detection and Classification, *Journal of Computing Theories and Applications*, Vol. 2, No. 3, Hal. 395–409, 2025.
- [9] Saheed, Y. K., Abiodun, A. I., Misra, S., Holone, M. K., Colomo-Palacios, R., A Machine Learning-Based Intrusion Detection for Detecting Internet of Things Network Attacks, *Alexandria Engineering Journal*, Vol. 61, No. 12, Hal. 9395–9409, 2022.
- [10] Firdaus, F. S., Hatta, P., Basori, B., Evaluating Ensemble Versus Non-Ensemble Machine Learning Performance with Preprocessing Techniques for IoT Intrusion Detection on CIIoT2023, *Jurnal Teknik Informatika (JUTIF)*, Vol. 7, No. 1, Hal. 606–618, 2026.
- [11] Dzaki, M. H., Nugraha, A., Luthfiarta, A., Riyanto, A. A. R., Novandian, Y. D., Accelerating Classification for IoT Attack Detection Using Decision Tree Model with Gini Impurity Tree-Based Feature Selection Technique, *Jurnal Teknik Informatika (JUTIF)*, Vol. 6, No. 5, Hal. 3405–3418, 2025.

- [12] Sarhan, M., Layeghy, S., Portmann, M., Feature Analysis for Machine Learning-Based IoT Intrusion Detection, arXiv preprint arXiv:2108.12732, 2022.
- [13] Bensaoud, A., Kalita, J., Optimized Detection of Cyber-Attacks on IoT Networks via Hybrid Deep Learning Models, arXiv preprint arXiv:2502.11470, 2025
- [14] Nourildean, S. W., Ahmed, W. K., Sabri, A. A., Aziz, M., Intrusion Detection System Based Ensemble Machine Learning Model in AIoT Against Cyber Attacks, in Prosiding ASET 2025, Dubai, 2025, Hal. 1–7.
- [15] Premalatha, D. V., Ramanujam, S., Ensemble-Based Intrusion Detection for IoT Networks Using the CICIOT2023 Dataset, Journal of Information Systems Engineering and Management (JISEM), Vol. 10, No. 21s, 2025.
- [16] Gutierrez, J. A., Survey on Intrusion Detection Systems Based on Machine Learning Techniques for the Protection of Critical Infrastructure, Sensors, Vol. 23, No. 5, Art. No. 2415, 2023.
- [17] Vassiliou, V., Network Attack Classification in IoT Using Support Vector Machines, Journal of Sensor and Actuator Networks, Vol. 10, No. 3, Art. No. 58, 2021.
- [18] Chawla, N. V., Bowyer, K. W., Hall, L. O., Kegelmeyer, W. P., SMOTE: Synthetic Minority Over-sampling Technique, Journal of Artificial Intelligence Research, Vol. 16, Hal. 321–357, 2002.
- [19] Sokolova, M., Lapalme, G., A Systematic Analysis of Performance Measures for Classification Tasks, Information Processing & Management, Vol. 45, No. 4, Hal. 427–437, 2009.
- [20] Khraisat, A., Gondal, I., Vamplew, P., Kamruzzaman, J., Survey of Intrusion Detection Systems: Techniques, Datasets and Challenges, Cybersecurity, Vol. 2, Art. No. 20, 2019.
- [21] Lundberg, S. M., Lee, S. I., A Unified Approach to Interpreting Model Predictions, Advances in Neural Information Processing Systems (NeurIPS), Vol. 30, Hal. 4765–4774, 2017.
- [22] Al-Shibly, I., Burgas, L., Massana, J., Interpretable Intrusion Detection for IoT: A CNN-BiLSTM Permutation Importance Framework for Deep Feature Selection, Frontiers in Big Data, Vol. 9, Art. No. 1813265, 2026.
- [23] Alahmari, S., Aleisa, N., Enhancing the CIC IoT Dataset 2023 for Improved Attack Detection through GANs Augmentation and Federated Learning, Journal of Computer Science, Hal. 1688–1704, 2025.